

RAG 问答机器人评估报告

评估对象：云帆ERP智能客服 RAG（离线混合检索 + 抽取式回答；配置大模型 API Key 后生成层切换为 LLM，检索链路不变）

测试集：**100 题**（项目③ VoC 真实客户提问 60 题 + 人工跨模块补充 40 题），覆盖 15 个帮助模块

评估日期：2025-09（本地离线可复现，`python tests/eval_rag.py`）

1. 评估指标与方法

指标	定义
Recall@K	Top-K 召回块中是否包含期望模块（检索能不能找到正确资料）
MRR	第一个正确模块块的倒数排名（正确资料排得靠不靠前）
模块精度 ModPrec@K	Top-K 中属于期望模块的块占比（引用正确率的代理：噪声块越少，LLM 被干扰越少）
转人工率 Handoff	Top1 相似度低于置信阈值而兜底转人工的比例
答案关键词覆盖率	抽取式答案命中该题期望关键词的比例（40 道人工题人工标注关键词）

检索方案为**词级 TF-IDF（1-2gram，叠加低权重同义词扩展） + 字符 ngram（char_wb 2-3gram）混合余弦**，并对多字符实词的标题命中加权。字符 ngram 解决错字、英文/中文混写与未登录词；同义词扩展解决客户口语与文档术语不一致（如“不回传”→“回传失败/批量补传”）。

2. 一次真实修复：默认示例问题离线答不出

现场演示的第一题“物流单号一直不回传怎么办？”在初版离线模式下错误转人工，拆解为两个独立断点：

- 1. **检索**：含“五步排查”原文的块排第二（0.0983），“跟踪号管理与换号”块靠标题词面命中排第一；
- 2. **抽取**：排查句（“回传失败进入重试队列，前3次间隔15分钟”）不重复提问原词，词覆盖率最高仅 0.33，被 0.34 的硬阈值全部砍掉，抽取结果为空 → 触发兜底。

修复（评估驱动，非拍脑袋）：

- **查询扩展**：建立约 40 条“客服口语→文档术语”短语表（词条归纳自项目③真实提问），在原文上做子串匹配，扩展词以 0.5 低权重只注入词级 TF-IDF 向量，避免带偏召回；
- **抽取阈值配置化**：词覆盖门槛 0.34→**0.25**（常量 `EXTRACT_COVER_THRESHOLD`），覆盖率只计多字符实词并把扩展词计入；每个召回块最多贡献 2 句；切句不再在“；”断开，保留完整排查序列。

修复后该题离线回答包含完整排查顺序与“重新回传/批量补传”操作路径，且全部句末带来源编号。

3. 消融实验：查询扩展到底有没有用

在选定配置（标准切块 / 词权重 0.6 / TopK=5）上做开关对比：

查询扩展	Recall@5	MRR	模块精度	转人工率	答案关键词覆盖	答案产出率
关	0.97	0.8725	0.538	0.06	0.8289	0.95
开 (选定)	0.97	0.8938	0.558	0.05	0.859	0.975

扩展开启后 MRR 提升约 2 个点、模块精度提升 2 个点，答案关键词覆盖从 0.83 提升到 0.86，答案产出率（curated 40 题中成功组织出答案的比例）从 0.95 提升到 **0.975**，且 Recall 与转人工率无劣化。扩展词表同时修复了“订单量超了套餐额度怎么办”等口语问法（能答出超额计费规则原文）。

4. 全量迭代实验记录（切块 × TopK × 词权重）

切块策略	TopK	词权重	扩展	Recall	MRR	模块精度	转人工率
std-200-500+扩展(选定)	5	0.6	1	0.97	0.8938	0.558	0.05 (选定)
std-200-500	5	0.7	0	0.97	0.8731	0.542	0.05
std-200-500	5	0.6	0	0.97	0.8725	0.538	0.06
std-200-500	5	0.5	0	0.97	0.8708	0.548	0.07
small-240	5	0.5	0	0.95	0.8585	0.592	0.05
std-200-500	3	0.6	0	0.94	0.8725	0.62	0.06
std-200-500	3	0.5	0	0.94	0.8708	0.6233	0.07
small-240	5	0.6	0	0.94	0.8621	0.584	0.05
small-240	5	0.7	0	0.93	0.8528	0.582	0.05
std-200-500	3	0.7	0	0.92	0.8731	0.62	0.05
small-240	3	0.6	0	0.89	0.8621	0.6567	0.05
small-240	3	0.5	0	0.89	0.8585	0.6567	0.05
small-240	3	0.7	0	0.89	0.8528	0.66	0.05

实验结论（每一步调参的取舍）

1. 切块大小：标准 200-500 字（模块级贪心打包）优于约 240 字小窗口。小窗口把同小节的上下文拆散，排查步骤类内容被分到两个块，Recall 低 2 个点；模块级打包还让相邻小节（跟踪号一回传失败）共处一块，

反而对“单号不回传”这类跨小节问题友好。

2. **TopK: 选定 K=5**。K=3 模块精度更高，但漏掉正确块的概率增加约 3 个百分点；K=5 以可接受的精度损失换召回，再由生成层 prompt 约束只依据资料作答、引用编号，控制噪声影响。
3. **词权重选定 0.6 / 字符 0.4**：纯词面匹配对错字与英文报错码不够鲁棒，纯字符又会引入同形噪声；0.6 为网格最稳区间。
4. **置信阈值 0.11 保持不动**：扩展后域内最低分问题（“新手第一次用先学哪几个模块”，0.098）与最像业务问题的越界提问（“推荐几本科幻小说”，0.092）之间仅有 0.006 的余量，为单题压低阈值会让兜底失去保护——宁可对这 1/40 题安全转人工，不冒误导风险。

5. 最终效果

- **Recall@5 = 0.97, MRR = 0.8938, 模块精度 = 0.558**;
- **抽取式答案关键词覆盖 = 0.859, 答案产出率 = 0.975**;
- 40 道人工题中错误转人工 1 题（安全失败）；越界问题（老板是谁、天气、写诗、查余额）全部正确兜底；
- 修复后的默认示例问题可离线给出完整排查步骤与操作入口，断网环境演示链路完整。

6. 已知局限与下一步

1. 长且口语化的问题（“新手第一次用先学哪几个模块”）被通用词拉低余弦分，处于阈值下方；下一步可对问题先做停用词压缩或用 embedding 语义检索；
2. 同义词表靠人工维护（约 40 条），扩词来源应持续接入项目③的新提问；接入 embedding 后可用“未命中问题挖掘”自动发现新词；
3. 生成质量在配置 LLM API Key 后应重新评估：答案正确性需人工逐条标注（当前抽取式用关键词覆盖率代理）；
4. 测试集期望标签是“模块级”，未来可升级到“文章级/块级”标注，做更严格的引用正确率。